

Spotify : Qu'est-ce qui rend une chanson populaire ?

Analyse du Top 100 Spotify 2010-2019 : SQL, Python, HTML/CSS/JavaScript

Réalisé par : Gabriel BERTRAND

Note : *projet personnel mené par intérêt pour l'analyse de données appliquée à la musique. Nettoyage des données, modélisation et requêtes en SQL, analyse statistique en Python, dashboard interactif via HTML/CSS/JavaScript, et un test de robustesse sur un dataset 89x plus large (partie 7).*

1. Contexte et objectif

Point de départ du projet : un label musical fictif veut donner à ses artistes des recommandations concrètes sur les caractéristiques d'une chanson qui la rendent populaire, afin de maximiser les chances de succès de ses prochaines sorties. C'est le cadre business que je me suis fixé pour structurer l'analyse.

Question posée : quelles caractéristiques (genre, tempo, énergie, danceability, configuration de l'artiste...) sont associées aux titres les plus populaires du Top 100 Spotify sur la décennie 2010-2019 ?

Hypothèses de travail

- Le genre musical influence fortement la présence dans le Top 100 et la popularité moyenne.
- Les caractéristiques audio (énergie, danceability, valence) des titres populaires évoluent dans le temps.
- La configuration de l'artiste (solo, duo, groupe) est associée à des niveaux de popularité différents.
- Les caractéristiques audio, seules, permettent de prédire raisonnablement la popularité d'un titre.

La dernière hypothèse est délibérément mise à l'épreuve plutôt que supposée vraie : voir sections 5 et 7.

2. Données et méthodologie

2.1 Source des données

Dataset Kaggle *"Top Spotify Songs from 2010-2019 by year"* (1000 titres, 19 colonnes), enrichi d'une colonne *"artist_type"* (Solo / Duo / Trio / Groupe).

2.2 Nettoyage des données (Python)

Script : `python/01_clean_data.py`. Étapes principales :

- Renommage des colonnes cryptiques du fichier source (L, r, rank, nrgy, dnce...) en noms explicites (title, chart_position, artist, energy, danceability...).
- Typage des colonnes numériques et de dates.
- Détection et correction d'un problème de qualité de données réel : cinq titres purement numériques ("212", "3005", "22"...) et un titre auto-corrompu par Excel : "7/11" de Beyoncé, converti automatiquement en fraction décimale (0.636363...) par Excel. Sans ce correctif, 6 lignes auraient été perdues au nettoyage.

- Feature engineering : décennie de sortie, tranche de popularité (Low/Mid/High/Very High), proxy de contenu “parlé” (speechiness élevée), détection des titres réapparaissant sur plusieurs années.

Résultat : 1000 lignes conservées (0 perte), 23 colonnes, exportées vers data/spotify_clean.csv.

2.3 Modélisation en base SQL

Script : python/02_build_db.py, construit une base SQLite en schéma en étoile à partir du CSV nettoyé (voir le glossaire, section 8, pour une explication de ce terme), le même schéma que celui recommandé pour Power BI (voir section 5) :

dim_artist(artist_id, artist_name, artist_type)	444 artistes
dim_genre(genre_id, genre_name)	132 genres
fact_songs(song_id, title, chart_year, ..., artist_id, genre_id)	1000 titres

Ce choix (plutôt qu'une seule table plate) permet d'écrire de vraies jointures en SQL et prépare directement le modèle relationnel attendu par Power BI.


2.4 Requêtes SQL d'analyse

Fichier : sql/analysis_queries.sql, 11 requêtes couvrant CTE, fonctions fenêtre (ROW_NUMBER, LAG), agrégations, jointures et sous-requêtes. Extrait représentatif (top 3 titres les plus populaires par année, technique “top-N par groupe” très demandée en entretien) :

```
WITH ranked AS (
  SELECT f.chart_year, f.title, a.artist_name, f.popularity,
         ROW_NUMBER() OVER (
           PARTITION BY f.chart_year ORDER BY f.popularity DESC
         ) AS rn
  FROM fact_songs f JOIN dim_artist a ON a.artist_id = f.artist_id
)
SELECT chart_year, title, artist_name, popularity
FROM ranked WHERE rn <= 3 ORDER BY chart_year, rn;
```

Toutes les requêtes ont été exécutées et validées (python/03_run_queries.py) ; les 11 jeux de résultats sont exportés dans data/query_results/.

3. Insights clés (Top 100, 2010-2019)




Top 10 genres par nombre d'apparitions dans le Top 100 (2010-2019)

La dance pop domine très largement (36% des titres classés), loin devant la pop (5,7%) et l'atl hip hop (3,9%). Un label misant sur ce genre maximise mécaniquement ses chances de présence dans les classements ; mais la section 7 montre que présence ne veut pas dire meilleure conversion en hit.

Qu'est-ce qui caractérise la pop ?


Point de contexte général sur le genre, pas un résultat tiré de ce dataset : utile pour comprendre pourquoi la dance pop, qui appartient à cette famille, domine autant les classements du Top 100.

- **Mélodies accrocheuses** : faciles à retenir et à chanter.
- **Rythme entraînant** : souvent en 4/4, avec une forte présence de percussions.
- **Structures simples** : couplet-refrain-pont, ce qui facilite l'écoute.
- **Production soignée** : instruments électroniques, synthétiseurs, effets vocaux.
- **Thèmes universels** : amour, relations, fête, émotions personnelles.



Évolution des caractéristiques audio moyennes, 2010-2019

- **L'énergie baisse régulièrement** : de 76,6 (2010) à 62,8 (2019), une tendance quasi monotone sur 10 ans.
- **La danceability bondit à partir de 2017** : de ~65 à plus de 73, portée par la vague "tropical/dance-pop" de la fin de décennie (Ed Sheeran, Dua Lipa, Post Malone...).
- **La valence (positivité perçue, voir glossaire) touche un plancher en 2015-2016** avant de remonter légèrement en 2019.




Popularité moyenne par configuration d'artiste

Les groupes et les artistes solo affichent une popularité moyenne quasi identique (75,4 vs 75,0) ; les duos et trios sont légèrement en retrait (72,1 et 71,1). L'écart reste faible ; la configuration de l'artiste n'est pas un facteur déterminant, contrairement à l'hypothèse de départ.

4. Analyse statistique (Python)

Script : python/04_analysis.py (pandas + scikit-learn). Deux volets : corrélations entre variables audio, puis une régression linéaire pour quantifier ce qui explique la popularité.



Matrice de corrélation : caractéristiques audio et popularité

4.1 Corrélations validées

Relation	Corrélation trouvée	Hypothèse de départ
Énergie ↔ Loudness	0,71 (forte)	0,65 : confirmé, du même ordre
Danceability ↔ Valence	0,27 (modérée)	0,40 : surestimée au départ
Speechiness ↔ Popularité	0,06 (quasi nulle)	“Le contenu explicite a une popularité médiane plus haute” : non vérifiable avec ce proxy (voir glossaire : speechiness ≠ contenu explicite)

4.2 Qu'est-ce qui prédit vraiment la popularité ?


Une régression linéaire (popularité ~ 9 caractéristiques audio, split train/test 80/20) donne un R^2 de seulement 0,06 sur le jeu de test (voir glossaire pour la définition du R^2) : les caractéristiques audio, prises seules, expliquent moins de 6% de la variance de la popularité.

- **C'est le résultat le plus important de cette première partie** : contrairement à l'intuition de départ, le “son” d'un titre n'explique pas grand-chose de sa popularité. La section 7 teste si ce résultat tient sur un dataset bien plus grand.

Ce dataset ne contient aucune information sur l'artiste (nombre d'auditeurs, notoriété), la promotion, ou le placement en playlist ; des facteurs qu'on peut légitimement soupçonner de jouer un rôle, sans que ce projet permette de le démontrer. C'est une limite à garder en tête plutôt qu'une conclusion : voir aussi les sections 6 et 7.4.

5. Restitution : dashboard interactif

Un dashboard HTML interactif (fichier dashboard/spotify_dashboard.html) reprend l'ensemble des KPIs et graphiques ci-dessus dans une interface consultable au format web, avec bascule graphique/table et mode sombre.



Aperçu du dashboard interactif fourni (dashboard/spotify_dashboard.html)

6. Pistes pour le label (à partir du Top 100 seul)

- **Ne pas sur-indexer sur le genre** : la dance pop domine en volume mais n'a pas une popularité individuelle nettement supérieure aux autres genres (74,0 en moyenne, proche de la médiane globale de 74,8).
- **Le faible R^2 invite à s'interroger sur d'autres leviers** : si l'audio seul explique si peu la popularité, on peut se demander si des facteurs comme le placement en playlist ou la stratégie de sortie ne pèsent pas davantage que le retravail du son d'un titre ; une hypothèse que ce dataset ne permet pas de trancher, faute de données sur l'artiste ou la promotion, mais qui mériterait d'être creusée avec les bonnes données.
- **Suivre la tendance danceability** : la hausse nette depuis 2017 suggère un goût du marché pour des morceaux plus dansants, quitte à réduire l'énergie brute perçue.
- **Rester prudent sur les corrélations isolées** : energy et loudness sont si fortement liées ($r = 0,71$) qu'il ne faut pas les traiter comme deux leviers indépendants dans une recommandation produit.

Ces pistes reposent sur 1000 titres qui sont tous déjà des hits (Top 100). La section suivante teste si elles tiennent sur un échantillon 89x plus large, incluant aussi les titres qui n'ont jamais percé.


7. Aller plus loin : test sur un dataset 89x plus large

Question posée après la première version de l'analyse : avec un dataset plus large, obtiendrait-on davantage de conclusions ? Réponse testée, pas supposée.

7.1 Le vrai problème n'est pas le volume, c'est le biais d'échantillon

Le dataset original (1000 titres) est exclusivement composé de hits (Top 100 de chaque année) : la popularité y varie dans une fenêtre étroite (60-100). C'est un biais de restriction de gamme classique en statistiques, qui écrase mécaniquement les corrélations observables. Pour le tester, un second dataset a été mobilisé : le "Spotify Tracks Dataset" (Kaggle, 114 000 titres, 114 genres), qui couvre tout le catalogue : hits ET flops, popularité de 0 à 100. Après dédoublement (un même titre peut être étiqueté sous plusieurs genres), 89 740 titres uniques restent (script python/06_clean_extended.py).

7.2 Le résultat surprend, et il est rapporté tel quel




L'hypothèse de départ ("un dataset plus large et non biaisé donnerait un R^2 nettement plus élevé") n'est PAS confirmée : le R^2 reste très faible sur les 89 740 titres (0,028), et même légèrement plus bas sur le sous-ensemble "hits uniquement" de ce nouveau dataset (0,022) que sur le dataset original (0,06). Ajouter des variables supplémentaires (explicit réel, key, mode, time_signature) ne change presque rien ($R^2 = 0,031$, soit +0,003).


- **Ce que ça confirme, avec beaucoup plus de robustesse qu'avant** : sur un échantillon 89x plus grand et totalement indépendant, la conclusion tient toujours : les caractéristiques audio seules n'expliquent pas finement la popularité d'un titre. Ce n'était pas un artefact du petit échantillon original.

7.3 Mais un dataset plus large répond à des questions que l'ancien ne pouvait pas poser

Prédire le score exact de popularité échoue, mais plusieurs questions différentes deviennent possibles avec des flops dans les données :



- **Distinguer un hit d'un titre quelconque fonctionne bien mieux que prédire un score fin** : une régression logistique "popularité ≥ 70 ou non" atteint un AUC de 0,715 (0,5 = hasard, 1,0 = parfait). Les hits ont un profil reconnaissable : moins instrumentaux, moins acoustiques, plus forts en loudness, plus dansants ; même si, une fois dans ce groupe, l'audio ne dit presque rien de qui deviendra un 75 ou un 95 de popularité.
- **Le contenu explicite (métadonnée réelle, plus fiable qu'un proxy) est associé à une popularité plus élevée** : 36,9 en moyenne contre 32,9 pour le contenu non-explicite. C'est une association statistique observée sur 89 740 titres (comparaison de moyennes, confirmée dans la régression multivariée avec un coefficient positif) ; pas une preuve de causalité, et l'écart reste modeste. Mais c'est une confirmation bien plus solide que dans le dataset original, où seul un proxy peu fiable (speechiness, corrélation quasi nulle) avait pu être testé.
- **Tonalité (key) et mode (majeur/mineur) ont aussi été testés** : les titres en mode mineur ont une popularité légèrement supérieure aux titres en mode majeur (33,64 vs 32,95), et l'écart entre la tonalité la plus populaire (Mi, 34,06) et la moins populaire (Sol, 32,61) n'est que de 1,45 point sur une échelle de 100. Ces écarts sont statistiquement significatifs (test t et ANOVA, $p < 0,0001$) uniquement parce que l'échantillon est énorme (89 740 titres) ; en pratique, la tonalité et le mode n'ont quasiment aucun pouvoir explicatif sur la popularité. C'est un bon rappel qu'un résultat "statistiquement significatif" n'est pas toujours un résultat qui compte dans les faits.



Popularité moyenne par macro-genre, catalogue complet (89 740 titres)

- **Le classement des genres change du tout au tout hors du biais “Top 100”** : sur le catalogue complet, pop et hip-hop/r&b sont les macro-genres les plus populaires en moyenne (42,2 et 41,4) ; jazz/soul/funk et folk/country les moins populaires (28,7 et 29,7). C'est une lecture impossible avec le dataset original, qui ne contenait que des titres déjà populaires.
- **Le taux de conversion en hit par genre est la conclusion la plus actionnable de cette extension** : hip-hop/r&b convertit 10,5% de ses titres en hits (popularité ≥ 70), contre 8,0% pour la pop et à peine 1,2% pour classical/instrumental. Electronic/dance publie le plus grand volume de titres (16 639) mais ne convertit qu'à 3,5% ; gros volume ne veut pas dire bon taux de succès (requête SQL Q5, `sql/extended_analysis_queries.sql`).

7.4 Ce qu'on peut en tirer, prudemment

La conclusion générale tient : le son seul ne suffit pas à expliquer la popularité d'un titre, même sur un échantillon très large et indépendant. On peut légitimement se demander si d'autres facteurs, la notoriété de l'artiste, le budget promotionnel, le placement en playlist, jouent un rôle plus important, mais ce dataset ne mesure aucun de ces éléments et ne permet donc pas de l'affirmer ; ce n'est qu'une piste à creuser, pas une conclusion établie ici.

Ce qu'un dataset plus large a en revanche permis, très concrètement, c'est de répondre à des questions que l'ancien dataset ne pouvait pas poser : le taux de conversion en hit par genre (hip-hop/r&b et pop en tête) n'existait pas comme signal possible tant que le dataset ne contenait aucun flop pour le calculer.

En résumé, la réponse à “un dataset plus large donnerait-il plus de conclusions” est oui, mais pas de la façon supposée au départ : plus de lignes n'a pas rendu le modèle de prédiction plus précis ; en revanche, un dataset structurellement différent, avec des flops, une métadonnée explicite réelle, et assez de volume pour calculer des taux de conversion par genre, a permis de répondre à des questions business que l'ancien dataset ne pouvait pas poser.

8. Glossaire

Définitions des termes techniques utilisés dans ce rapport, pour une lecture autonome.

- **Valence (positivité perçue)** : indicateur Spotify (0 à 100 dans ce rapport) qui mesure la positivité musicale véhiculée par un morceau. Un score élevé correspond à un titre qui sonne joyeux ou euphorique ; un score bas à un titre qui sonne triste ou sombre. C'est un descripteur calculé automatiquement par Spotify à partir du signal audio, pas un sondage auprès d'auditeurs.
- **Speechiness** : détecte la présence de paroles parlées plutôt que chantées. Proche de 100 = piste presque entièrement parlée (podcast, livre audio) ; entre ~33 et 66 = mélange chant/parlé (rap) ; en dessous de 33 = musique "normale". Ce n'est PAS un indicateur de contenu explicite (grossièretés). Dans la première version du projet, speechiness avait été utilisé comme proxy pour "contenu explicite", une approximation qui s'est révélée peu fiable (voir section 4.1 et section 7.3 pour le vrai flag explicite).
- **Contenu explicite (explicit)** : à ne pas confondre avec speechiness : c'est une métadonnée déclarée par le label ou le distributeur au moment de la mise en ligne du titre (comme une classification d'âge), pas quelque chose que Spotify déduit du son. Elle signale la présence de grossièretés, de références sexuelles, à la drogue ou à la violence dans les paroles. Un simple "Oui/Non" par titre (vrai/faux dans les données), disponible uniquement dans le dataset étendu de la section 7.
- **Loudness** : le volume sonore moyen du morceau, en décibels (dB), généralement entre -60 et 0. Plus la valeur est proche de 0, plus le morceau est fort/compressé au mixage.
- **Acousticness** : indice de confiance (0 à 100) que le morceau soit acoustique, c'est-à-dire produit sans instruments amplifiés électroniquement ni synthétiseurs. Une valeur élevée = probablement une version acoustique ; une valeur basse = production plus électronique.
- **Key (tonalité) et mode (majeur/mineur)** : la tonalité (Do, Ré, Mi...) et le mode (majeur ou mineur) du morceau, au sens musical classique. Analysés dans la section 7.3 : leur effet sur la popularité est statistiquement mesurable mais très faible en pratique (moins de 1,5 point d'écart sur 100).
- **R² (coefficient de détermination)** : mesure la part de variance de la variable qu'on essaie de prédire (ici, la popularité) expliquée par le modèle. Il varie de 0 à 1 : 0 = le modèle n'explique rien, 1 = le modèle explique parfaitement toutes les variations. Un R² de 0,06 veut dire que le modèle explique 6% des écarts de popularité entre titres ; c'est faible.
- **AUC** : mesure la capacité d'un modèle de classification (ici, "hit ou non") à bien distinguer les deux classes. 0,5 = équivalent au hasard, 1,0 = distinction parfaite. Un AUC de 0,715 est un résultat correct sans être excellent.
- **Significativité statistique vs pratique** : avec un très grand échantillon (89 740 titres), même un écart minuscule entre deux groupes peut devenir "statistiquement significatif" ($p < 0,05$) au sens mathématique, sans que cet écart soit assez grand pour avoir une importance réelle. La section 7.3 (tonalité, mode) en est un exemple direct.
- **Modélisation en étoile (star schema)** : une façon d'organiser une base de données pour l'analyse, avec une table centrale de "faits" (ici, chaque titre et ses statistiques) reliée à des tables de "dimensions" qui décrivent le contexte (l'artiste, le genre...). Représentée schématiquement, la table de faits est au centre et les dimensions autour, comme les branches d'une étoile, d'où le nom.

- **Ce qui n'est pas mesuré dans ces datasets** : la mélodie au sens propre (contour de la ligne mélodique), les paroles, la structure du morceau (couplet/refrain) et la qualité vocale. Une vraie analyse de mélodie demanderait une transcription du signal audio (MIDI), hors du périmètre de ce projet, et l'accès à certains endpoints Spotify a été restreint aux nouvelles applications développeur depuis fin 2024.
-

Annexe : fichiers du projet

- data/spotify_clean.csv, data/spotify.db : dataset original nettoyé + base SQL (1000 titres)
- data_v2/spotify_extended_clean.csv, data_v2/spotify_extended.db : dataset étendu nettoyé + base SQL (89 740 titres)
- data/query_results/, data_v2/query_results/ : résultats de toutes les requêtes SQL
- python/01 à 05 : pipeline sur le dataset original ; python/06 à 08 : pipeline sur le dataset étendu
- sql/analysis_queries.sql, sql/extended_analysis_queries.sql : 16 requêtes commentées au total
- dashboard/spotify_dashboard.html : dashboard interactif autonome
- Spotify_Project_Report.docx (ce document) : méthodologie, insights, glossaire